

Detección de anomalías en ECG con representaciones latentes y error de reconstrucción de un VAE

Ana Paula Tissera (atissera@udesa.edu.ar), Naomi Couriel (ncouriel@udesa.edu.ar)

Introducción

El análisis manual de señales de ECG (electrocardiográficas) es un proceso costoso, lento y altamente dependiente de especialistas, lo que dificulta su escalabilidad en entornos clínicos con alta demanda. Ante la creciente necesidad de diagnósticos, buscamos desarrollar herramientas automáticas capaces de detectar anomalías de forma confiable.

Objetivos

- Aprender representaciones latentes de señales ECG normales mediante un VAE 1D.
- Detectar anomalías a partir del error de reconstrucción del VAE.
- Clasificar las señales anómalas usando un clasificador XGBoost sobre los vectores latentes y la puntuación de reconstrucción.
- Evaluar el rendimiento del pipeline en las bases de datos públicas PTB-XL y Chapman-Shaoxing.

Datos y FMM

Datasets utilizados

- *PTB-XL ECG Dataset*: 21,837 registros de 12 derivaciones, 500 Hz.
- *Chapman-Shaoxing ECG Dataset*: 10,646 registros multiclase de arritmias.

Características morfológicas (FMM) y preprocesamiento

Se extrajeron 21 coeficientes que caracterizan la forma y fase de las onda mediante el modelo Fast Multipole Method, describiendo amplitudes y fases de las ondas P, Q, R, S y T.

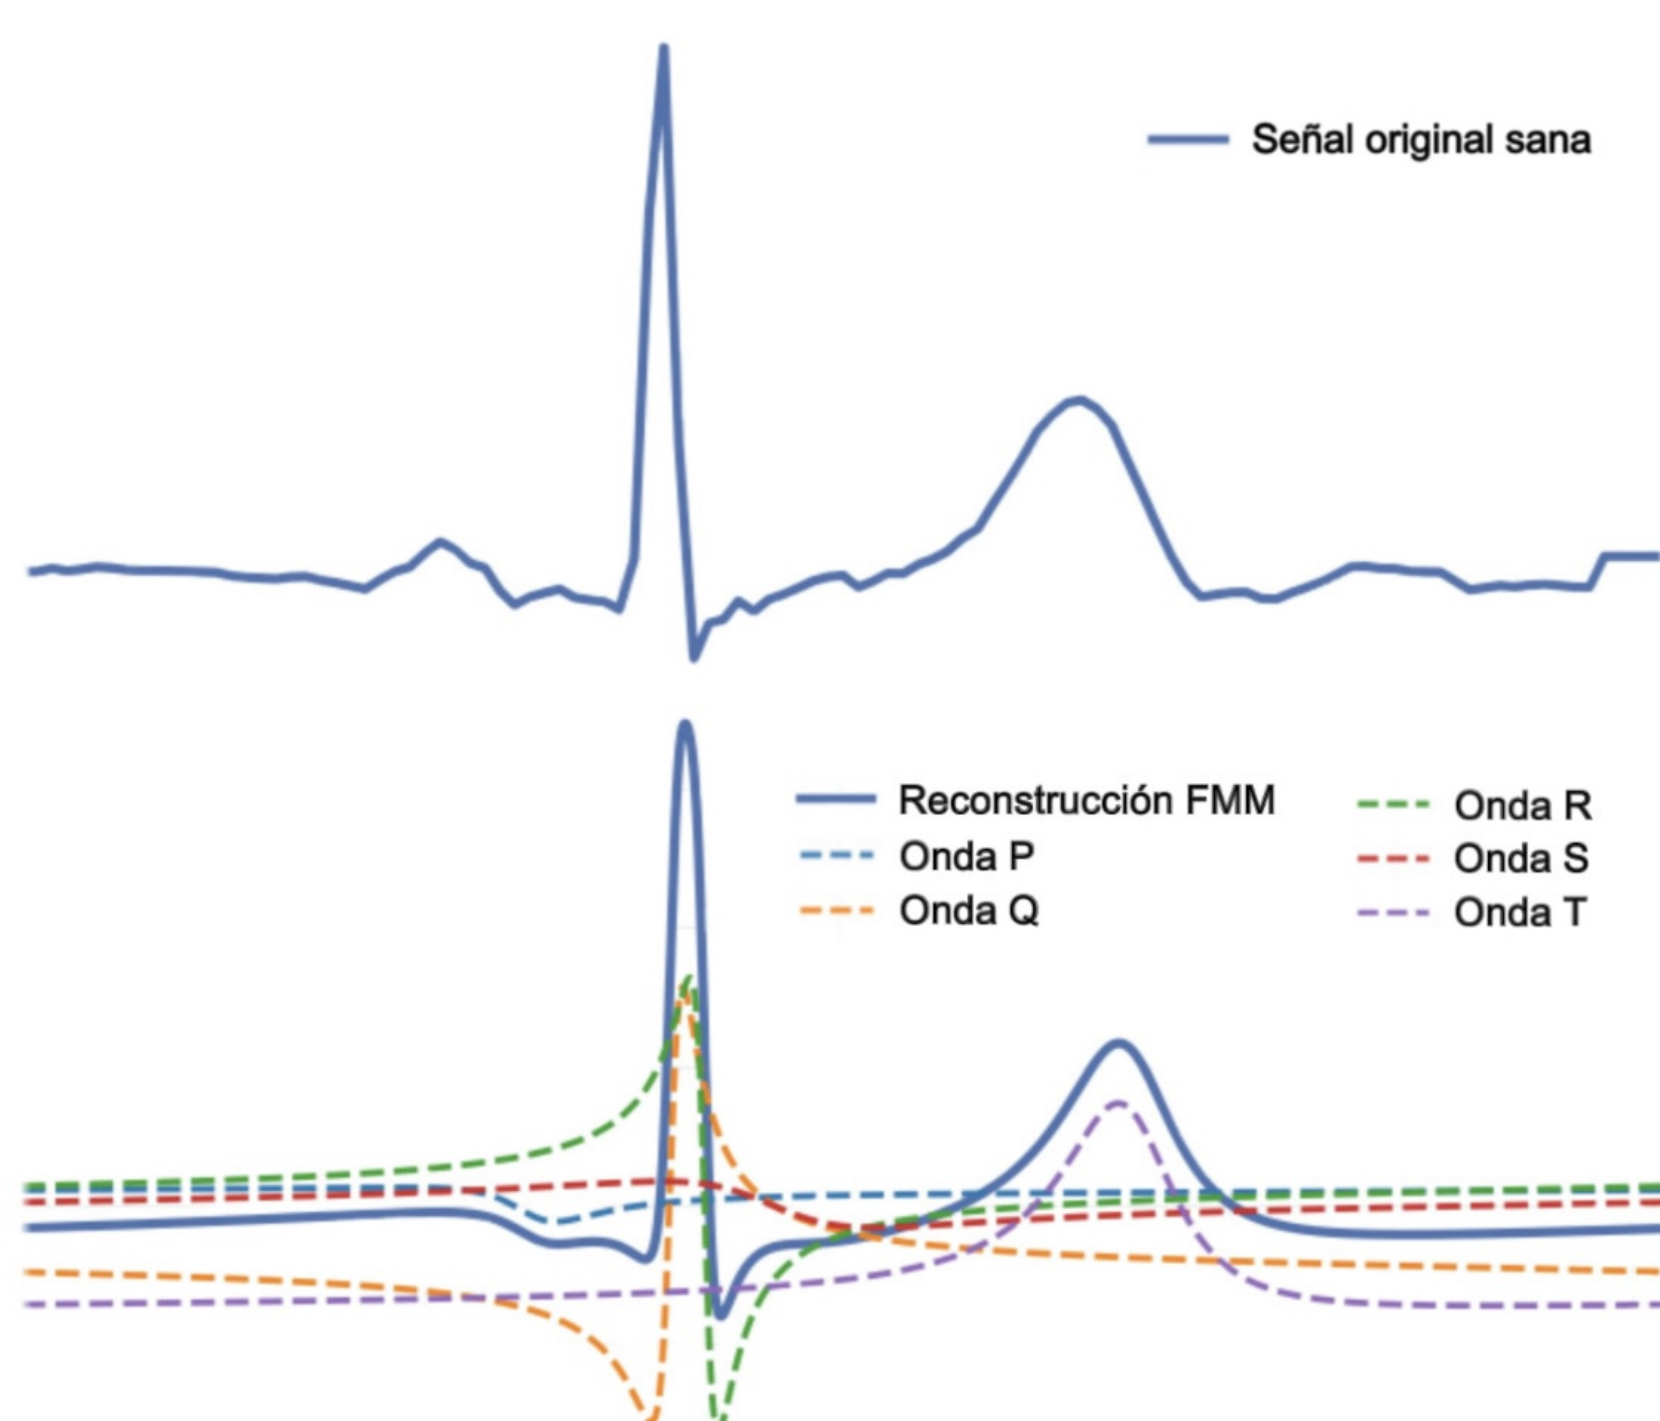


Figura 1: Señal de ECG y su reconstrucción mediante el modelo FMM.

Las ventanas de ECG se redimensionaron a longitud fija de 2048 muestras y cada una se normalizó mediante Z-score utilizando las estadísticas calculadas sobre el conjunto de entrenamiento.

Referencias

- [1] Verardo, Boman, Bruchfeld, Chiesa, Koch, Maguire Jr., y Kostic. *FMM-Head: Enhancing Autoencoder-based ECG anomaly detection with prior knowledge*, 2023.
- [2] Jang, Kim, Lim, y Yoon. *Unsupervised feature learning for electrocardiogram data using the convolutional variational autoencoder*, 2021.

Variational Autoencoder

El VAE comprime cada ventana de ECG junto con sus coeficientes FMM en un espacio latente y luego la reconstruye, de modo que el error de reconstrucción (ELBO) sirva como indicador de anomalía.

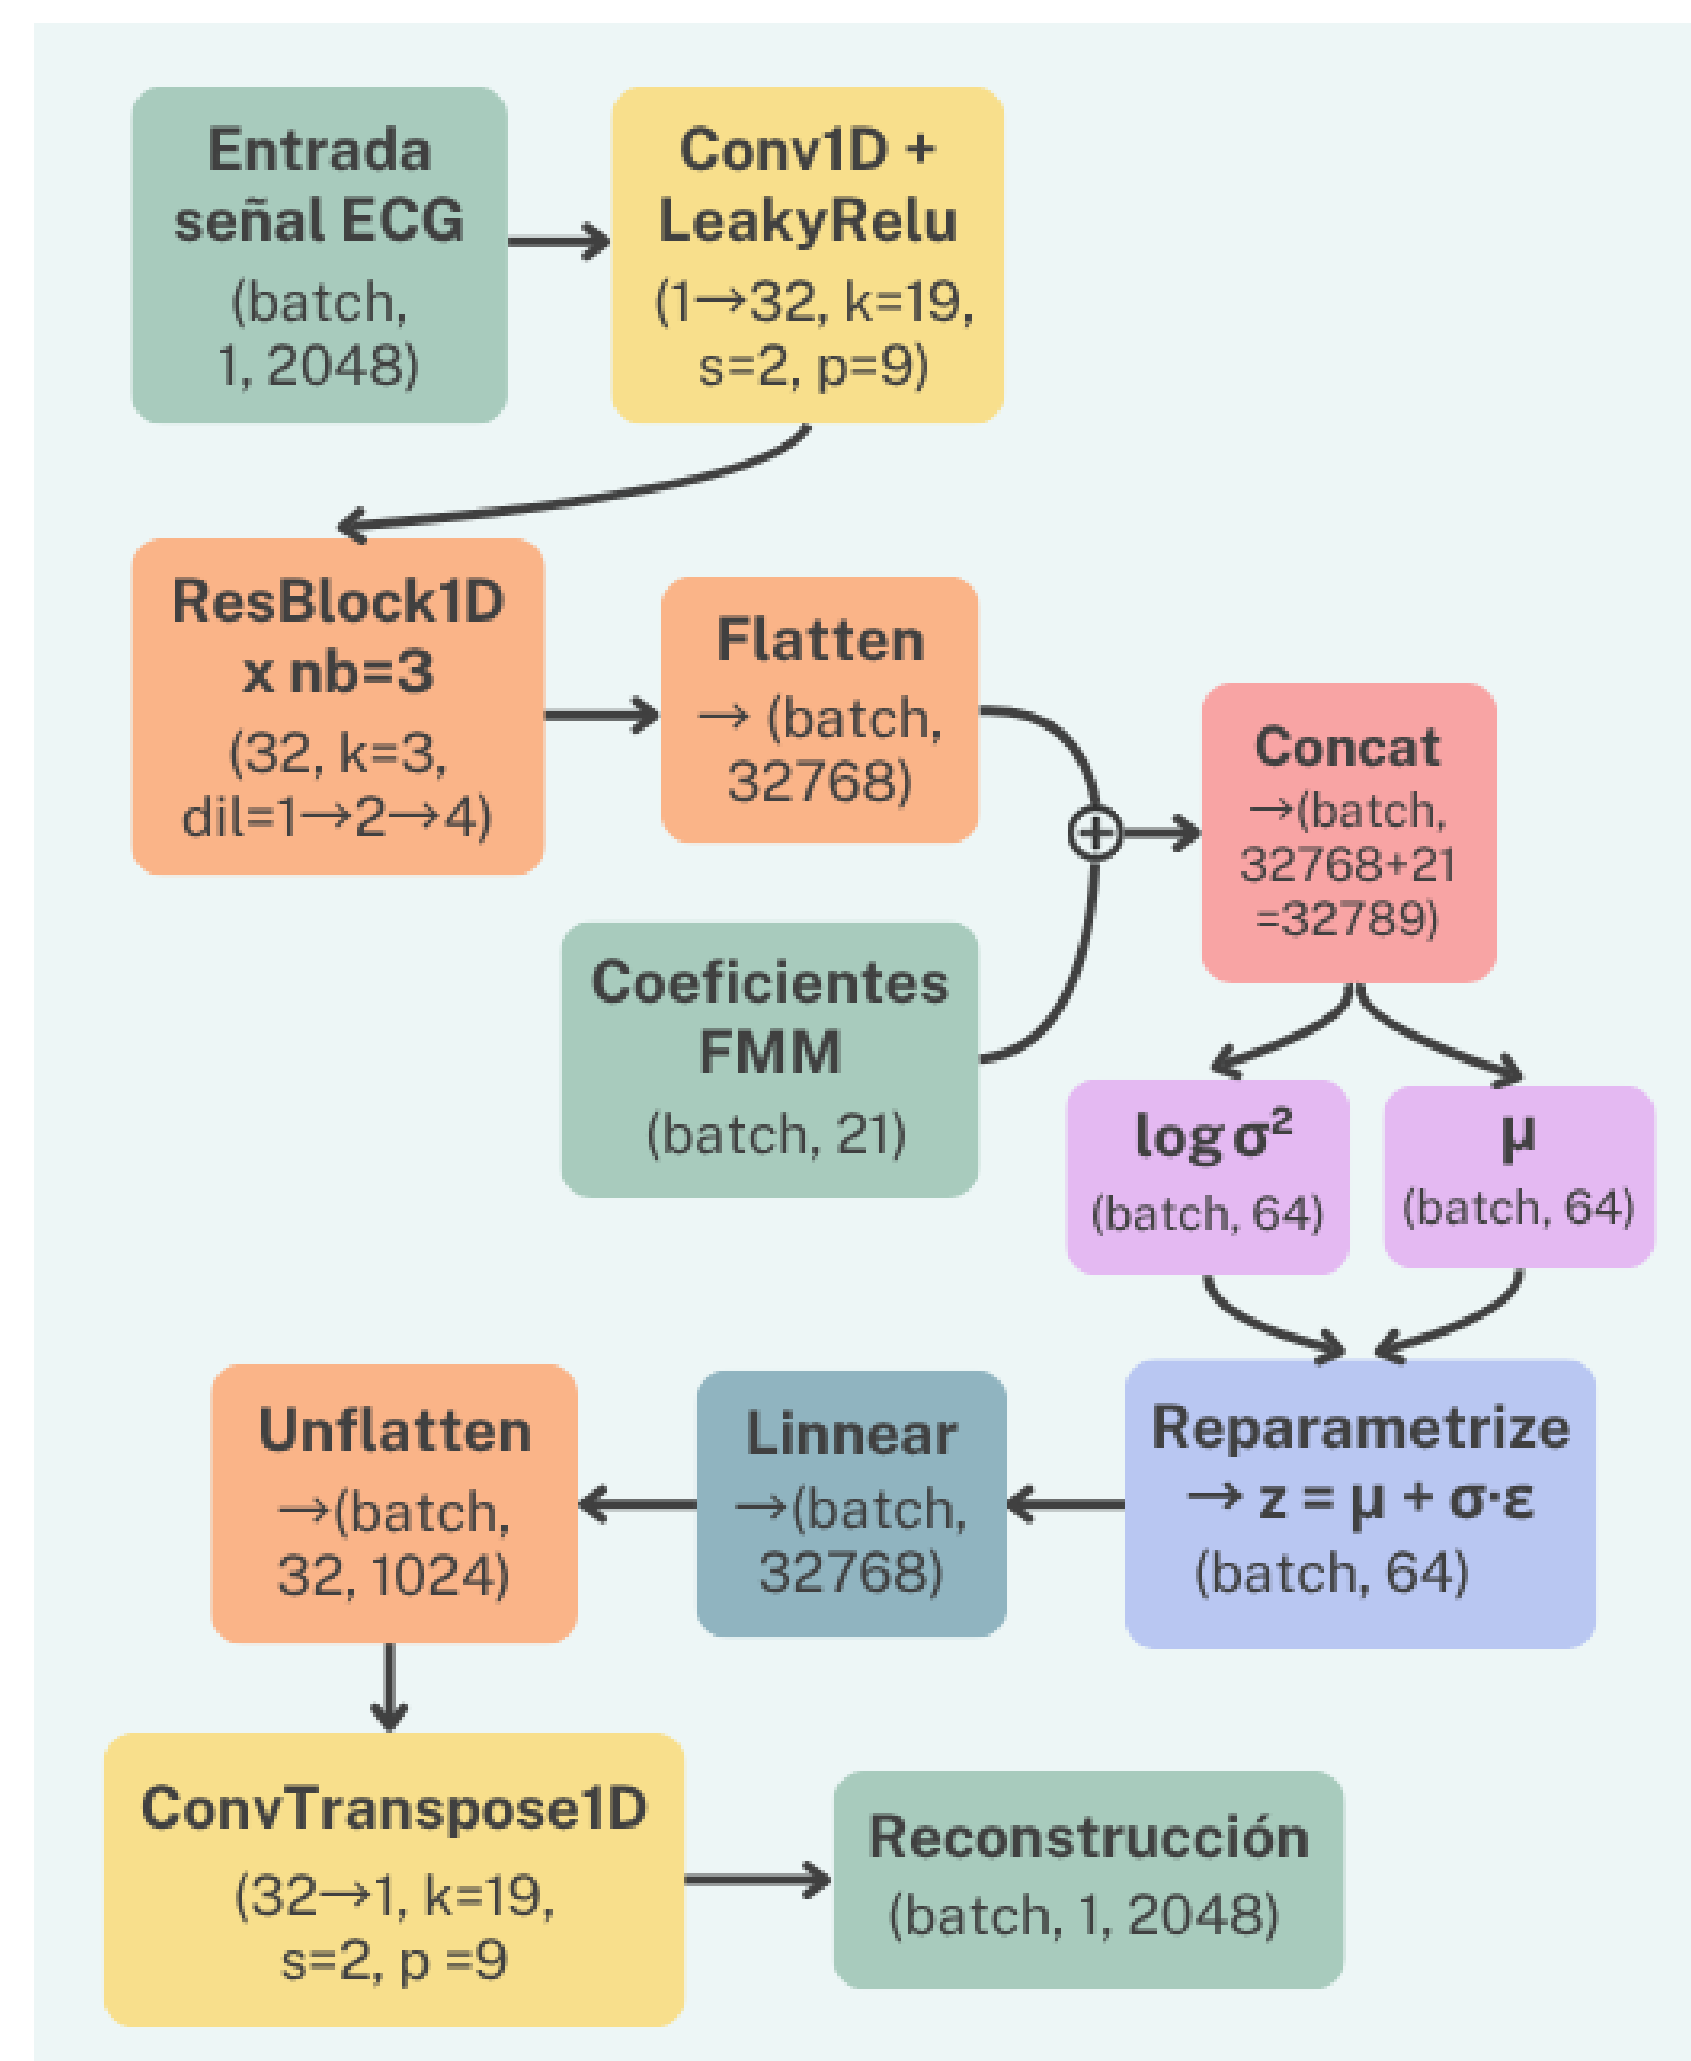


Figura 2: Arquitectura del VAE

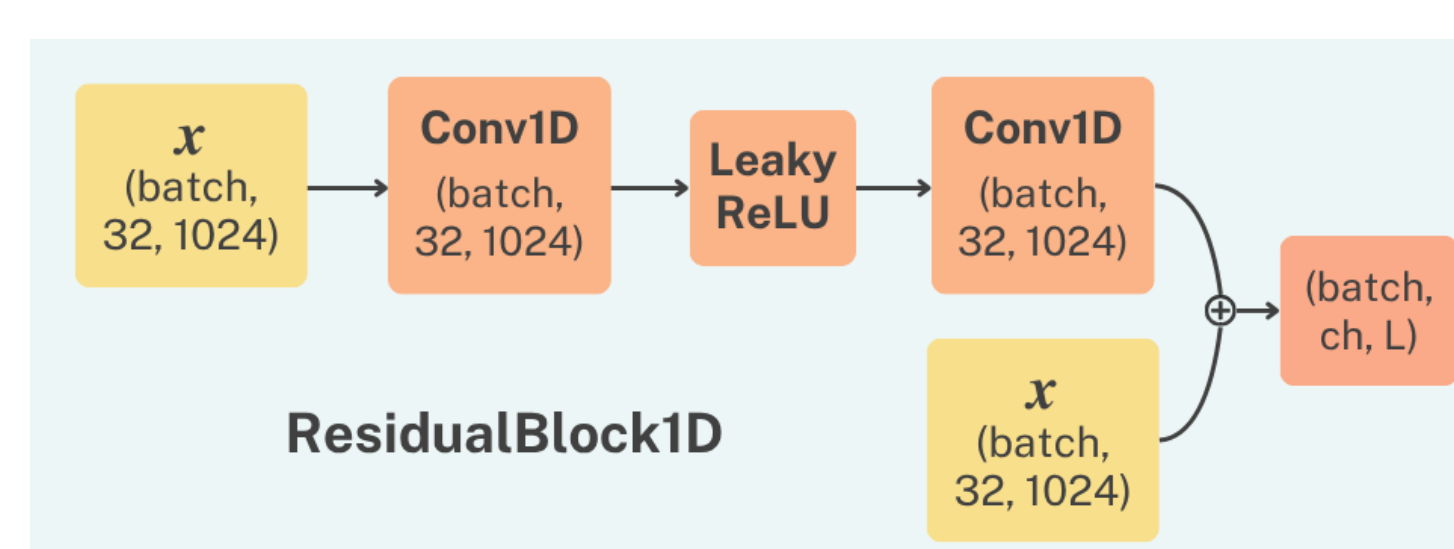


Figura 3: Arquitectura del Resize Block 1D

1. **Encoder:** recibe como entrada la señal ECG (2048 muestras) y el vector de coeficientes FMM. Extrae características y proyecta en dos vectores de parámetros latentes, μ y $\log \sigma^2$.
2. **Reparametrización:** a partir de μ y $\log \sigma^2$ se muestrea $z = \mu + \sigma \odot \epsilon$, $\epsilon \sim \mathcal{N}(0, I)$.
3. **Decoder:** toma z y genera la reconstrucción \hat{x} de la ventana ECG, tratando de aproximar la señal original.

Medida de Anomalía

$$4. \quad \text{ELBO} = - \underbrace{\text{MSE}(\hat{x}, x)}_{\text{reconstrucción}} - \beta \underbrace{\text{KL}(q(z | x) \| \mathcal{N}(0, I))}_{\text{regularización}}.$$

XGBoost

Una vez entrenado el VAE, se extrae un vector de características $c = [\mu, e] \in \mathbb{R}^{65}$ para cada señal, donde μ es el vector latente y e el error de reconstrucción. Este vector se utiliza para entrenar un clasificador XGBoost que realiza la predicción final (*Normal* vs. *Anómalo*).

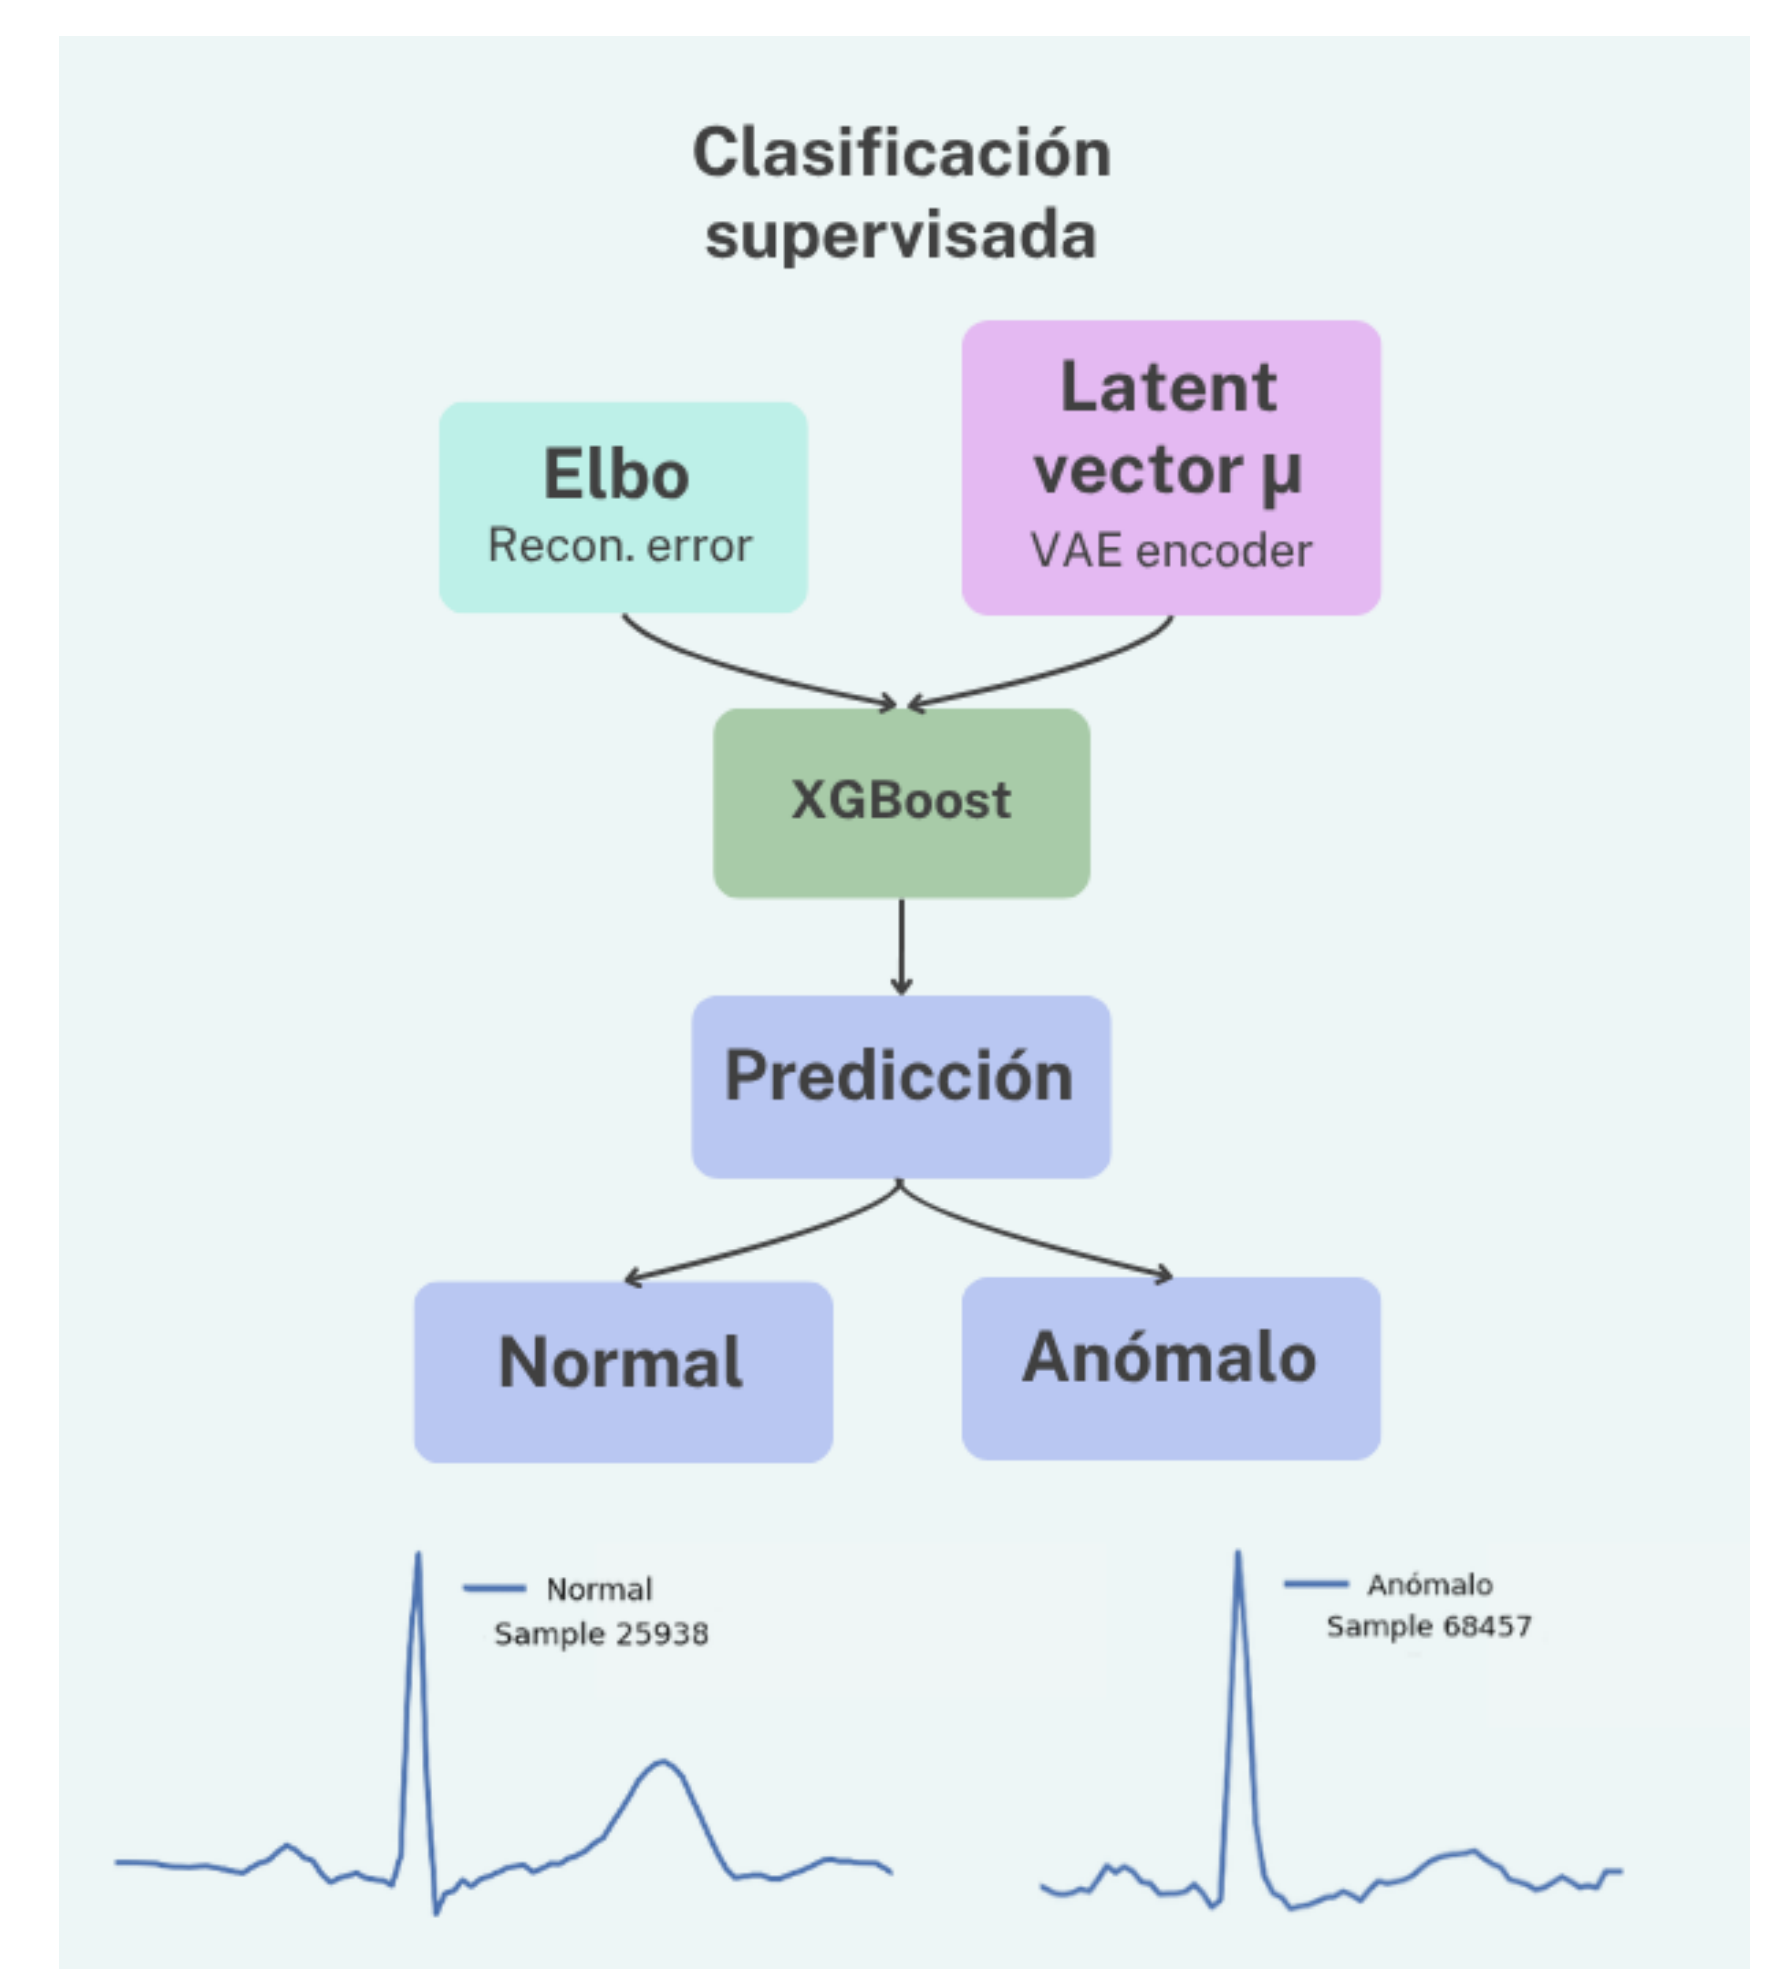



Figura 4: Clasificador del XGBoost

Conclusiones y Trabajo a Futuro

- El pipeline VAE + XGBoost logró detectar anomalías en ECG con alta precisión.
- El uso de coeficientes FMM aportó conocimiento morfológico muy útil al modelo.
- Se observó un trade-off entre precisión y recall, priorizando señales claras.
- A futuro, podrían incorporarse mecanismos de atención o datos sintéticos.

Resultados



Matrices de confusión: validación (izq.) y test (der.)

Los resultados numéricos del modelo final se resumen en la Tabla. Se observa un rendimiento general alto, con un AUC superior a 0.91 en el conjunto de prueba.

Métrica	Validación	Test
AUC-ROC	0.9235	0.9151
Precision	0.8780	0.9207
Recall	0.8276	0.7084
F1-score	0.8521	0.8007
Accuracy	0.8563	0.8237